

许嘉宁

Python / AI 工程后端实习生

138-0000-0004 | xu.jianing@example.com | 上海

教育经历

江南示例科技大学 | 人工智能 | 本科 | 2022.09—2026.06

课程：机器学习、深度学习、数据库、计算机网络、软件工程。

项目经历

课程问答模型服务平台 | 后端与推理服务 | 2025.03—2025.11

- 使用 FastAPI、PostgreSQL、Redis 和 Celery 实现模型版本、异步评测与流式生成接口。
- 设计请求状态机：鉴权、排队、prefill、decode、SSE 回传；记录 TTFT、TPOT、取消率与 GPU 队列长度。
- 按模型和模板哈希复用前缀缓存，设置租户隔离；压测中重复系统提示词场景 TTFT 中位数下降 31%。
- 对 500 条合成题做离线评测，区分 exact match、人工偏好和失败原因；未将测试集用于提示词调优。

实习经历

启明智能（虚构） | AI 平台实习生 | 2025.07—2025.10

- 封装统一模型网关，支持超时、重试、熔断和 token 预算；避免对非幂等生成请求盲目重试。
- 调研 continuous batching、PagedAttention、KV cache 量化与 speculative decoding，完成概念验证和限制说明。

技能

Python、FastAPI、PyTorch、PostgreSQL、Redis、Docker；理解 tokenizer、KV cache、批处理调度与模型评测基础。